Дисциплина: Анализ данных
Лабораторное задание №4

Отчет
Тема: Регрессионный анализ

Выполнил:
студент 3 курса 8 группы
Крутько А.С.

Проверила:
старший преподаватель
Юрова Я.А.

Оглавление

Постановка задачи. 3
Анализируемые данные 4
Практическая часть. 5
Вывод 5

Постановка задачи.

Целью данной работы было освоить использование проведение регрессионного анализа. Для чего требовалось выполнить следующее:

1. Используя заранее подготовленный набор данных определить его нормальность
2. Используя инструменты статистического пакета Statistica, получить данные для регрессионного анализа
3. Сделать вывод на основе полученных данных

Анализируемые данные

Для проведения данной работы мною были взяты данные с сайта kaggle.com на тему уровня счастья в мире по странам за 2015 год.

Рисунок 1 QR - код с ссылкой на сайт

Практическая часть.

При проведении регрессионного анализа мною была поставлена цель: определить зависимость между уровнем счастья населения страны и другими факторами. Для выполнения данной задачи были использованы следующие переменные:

1. Оценка счастья – величина, полученная в 2015 году путем опроса людей: «Как вы бы оценили, насколько вы счастливы по шкале от 0 до 10, где 10 – самый счастливый»
2. Экономика (ВВП на душу населения) – значение, показывающее в какой степени ВВП вносит вклад в расчёт показателя счастья
3. Семья – значение, показывающее в какой степени семья вносит вклад в расчёт показателя счастья.
4. Здоровье (продолжительность жизни) – значение, показывающее в какой степени продолжительность жизни способствовала расчёту показателя счастья.
5. Свобода - значение, показывающее в какой степени свобода способствовала расчёту показателя счастья.
6. Доверие (коррупция в правительстве) - значение, показывающее в какой степени восприятие коррупции способствовало расчёту показателя счастья.
7. Щедрость - значение, показывающее в какой степени щедрость способствовала расчёту показателя счастья
8. Остаточная антиутопия – символическое значение, отвечающее за уровень жизни в стране по сравнению с вымышленной худшей страной, хуже которой не может быть ни одна другая.

Для того, чтобы определить, насколько сильно влияют перечисленные факторы на оценку счастья, требовалось построить корреляционную матрицу:

Таблица 1 Корреляционная матрица

Variable	Correlations (happinnes.sta)							
	Экономика (ВВП на душу населения)	Семья	Здоровье (Ожидаемая продолжительнс сть жизни)	Свобода	Доверие (Коррупция в правительстве)	щедрость	Остаточная антиутопия	Оценка счастья
Экономика (В	1,000000	0,645299	0,816478	0,370300	0,307885	-0,010465	0,040059	0,780966
Семья	0,645299	1,000000	0,531104	0,441518	0,205605	0,087513	0,148117	0,740605
Здоровье (Ож	0,816478	0,531104	1,000000	0,360477	0,248335	0,108335	0,018979	0,724200
Свобода	0,370300	0,441518	0,360477	1,000000	0,493524	0,373916	0,062783	0,568211
Доверие (Корр	0,307885	0,205605	0,248335	0,493524	1,000000	0,276123	-0,033105	0,395199
щедрость	-0,010465	0,087513	0,108335	0,373916	0,276123	1,000000	-0,101301	0,180319
Остаточная ан	0,040059	0,148117	0,018979	0,062783	-0,033105	-0,101301	1,000000	0,530474
Оценка счасть	0,780966	0,740605	0,724200	0,568211	0,395199	0,180319	0,530474	1,000000

Таблица 2 Значения, полученные для первой корреляционной матрицы

Statistic	Summary Statistics; DV: Оценка счастья (happinnes.st Value
Multiple R	0,999999971
Multiple R?	0,999999942
Adjusted R?	0,999999939
F(7,150)	369509543
p	0
Std.Err. of Estimate	0,00028209624

По полученным данным видно, что значения у факторов «семья» и «здоровье» в пересечении с фактором «экономика» превышают 0,5, что обозначает их высокую значимость, поэтому нужно определить от какого именно фактора нужно избавиться в анализе. Для этого составим сводку регрессии, используя инструмент «Regression summary for Dependent Variable».

Таблица 3 Сводка регрессии

N=158	Regression Summary for Dependent Variable: Оценка счастья (happinnes.sta R= ,99999997 R?= ,99999994 Adjusted R?= ,99999994 F(7,150)=3695E5 p<0,0000 Std.Error of estimate: ,00028					
	b*	Std.Err. of b*	b	Std.Err. of b	t(150)	p-value
Intercept			0,000064	0,000125	0,51	0,607854
Экономика (ВВП на душ	0,352103	0,000040	1,000101	0,000113	8855,75	0,000000
Семья	0,237868	0,000027	0,999970	0,000115	8675,86	0,000000
Здоровье (Ожидаемая п	0,215761	0,000035	0,999883	0,000162	6175,10	0,000000
Свобода	0,131568	0,000026	0,999695	0,000198	5059,47	0,000000
Доверие (Коррупция в пр	0,104824	0,000023	0,999919	0,000224	4470,87	0,000000
щедрость	0,110648	0,000022	1,000061	0,000202	4956,27	0,000000
Остаточная антиутопия	0,483460	0,000020	1,000030	0,000042	24003,90	0,000000

По данной таблице видно, что значение b^* у фактора «здоровье» меньше, чем это же значение у фактора «семья», отсюда можно сделать вывод что фактор «здоровье» нужно убрать из нашего анализа.

Проводя для всех факторов вышеописанные действия несколько раз подряд мы должны прийти к корреляционной матрице следующего вида:

Таблица 4 Итоговая корреляционная матрица

Variable	Correlations (happinnes.sta) Экономика (ВВП на душу населения)	Свобода	Доверие (Коррупция в правительстве)	щедрость	Остаточная антиутопия	Оценка счастья
Экономика (ВВП на душу населения	1,000000	0,370300	0,307885	-0,010465	0,040059	0,780966
Свобода	0,370300	1,000000	0,493524	0,373916	0,062783	0,568211
Доверие (Коррупция в правительстве	0,307885	0,493524	1,000000	0,276123	-0,033105	0,395199
щедрость	-0,010465	0,373916	0,276123	1,000000	-0,101301	0,180319
Остаточная антиутопия	0,040059	0,062783	-0,033105	-0,101301	1,000000	0,530474
Оценка счастья	0,780966	0,568211	0,395199	0,180319	0,530474	1,000000

Таблица 5 Значения, полученные для финальной итоговой корреляционной матрицы

Statistic	Summary Statistics; DV: Оценка счастья (happinnes.st Value
Multiple R	0,97854194
Multiple R?	0,95754434
Adjusted R?	0,95614777
F(5,152)	685,641092
p	0
Std.Err. of Estimate	0,23977571

Таблица 6 Регрессионная сводка для итоговых данных

N=158	Regression Summary for Dependent Variable: Оценка счастья (happinnes.s R= ,97854194 R?= ,95754434 Adjusted R?= ,95614777 F(5,152)=685,64 p<0,0000 Std.Error of estimate: ,23978					
	b*	Std.Err. of b*	b	Std.Err. of b	t(152)	p-value
Intercept			0,507657	0,097459	5,20892	0,000001
Экономика (ВВП на душу населения	0,666569	0,018565	1,893300	0,052730	35,90559	0,000000
Свобода	0,202368	0,021210	1,537652	0,161162	9,54101	0,000000
Доверие (Коррупция в правительстве	0,066991	0,019691	0,639030	0,187832	3,40213	0,000855
щедрость	0,144582	0,018633	1,306769	0,168407	7,75961	0,000000
Остаточная антиутопия	0,507930	0,016930	1,050647	0,035020	30,00150	0,000000

В итоге, как видно на итоговой корреляционной матрице, из анализа мною были убраны следующие факторы: «Здоровье» (причина отбрасывания была описана выше), «Семья» (причиной отбрасывания было то, что на регрессионной сводке значение b^* было меньше, чем данное значение у фактора «Экономика (ВВП на душу населения)»).

Следующим шагом нашего анализа является проведение дисперсионного анализа данных, который требует нормальность входных данных. Таким образом, давайте определим нормальность модели:

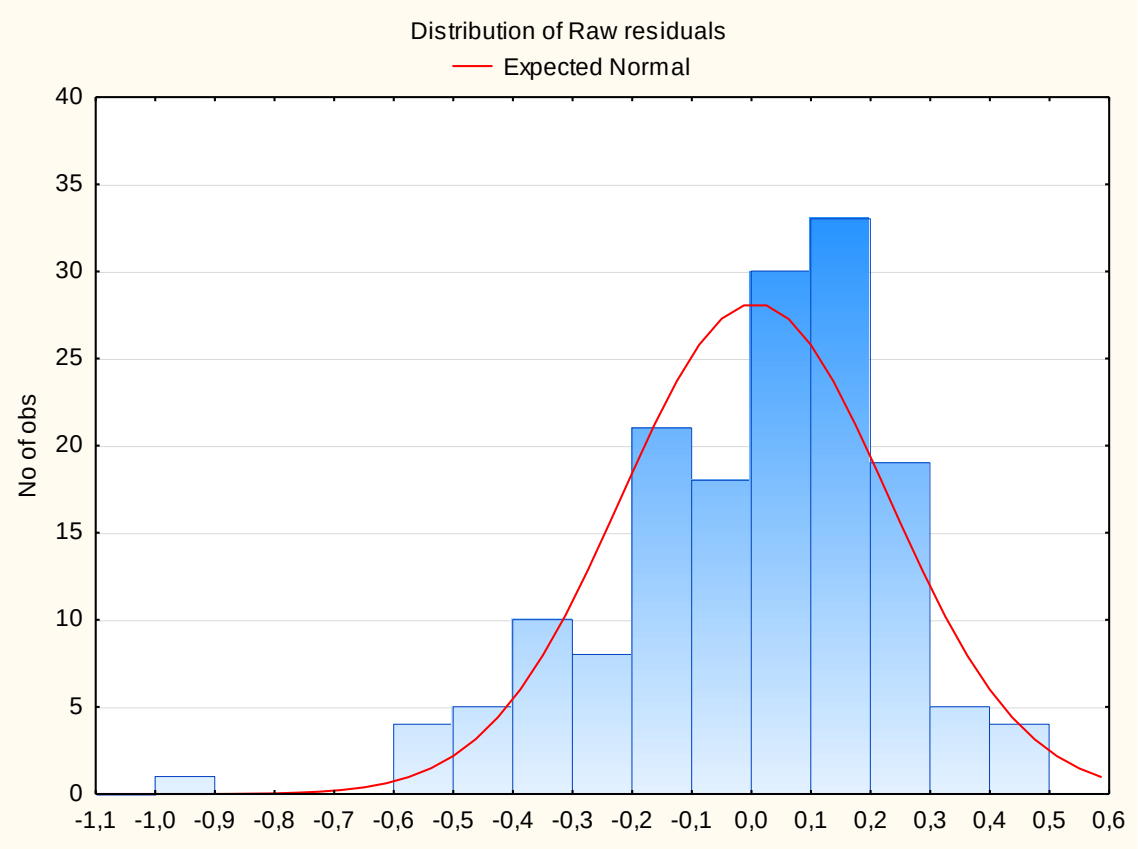

Рисунок 2 Распределение остатков

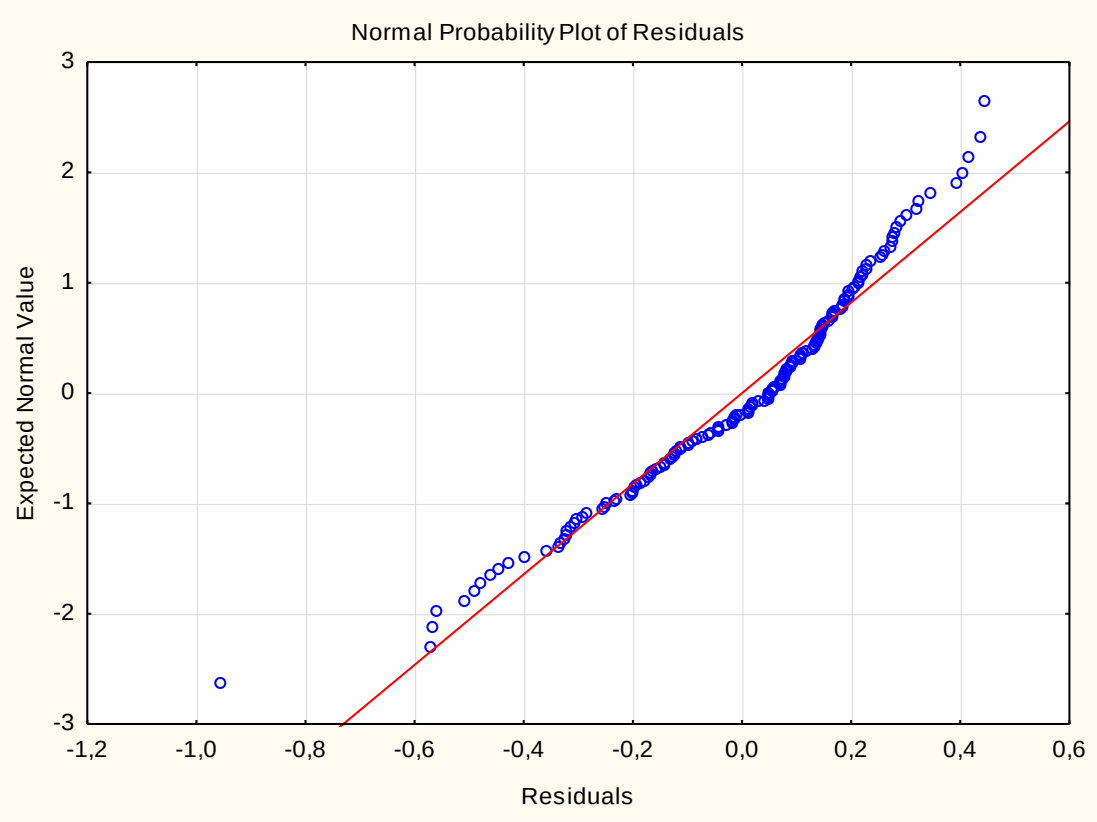

Рисунок 3 График нормальной вероятности остатков

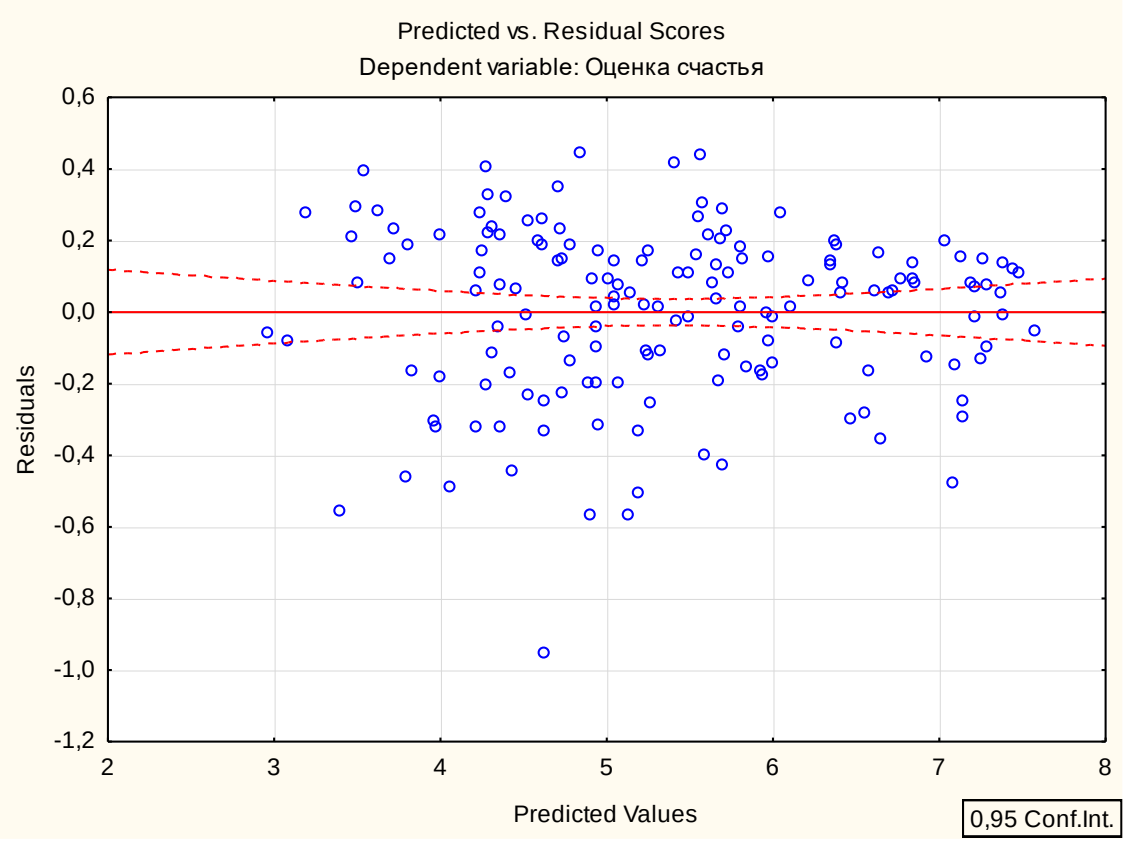

Рисунок 4 Прогнозируемая и остаточная оценка

На рис. 2 мы явно видим, что распределение остатков принимает вид нормального распределения, рис. 3 тоже указывает на нормальность модели, т.к. основные значения находятся вблизи прямой нормального распределения и только на концах присутствует разброс в небольшом количестве, по рис. 4 можно заметить что все точки разбросаны хаотично и явной закономерности между их положением выявить нельзя. Таким образом, можно сделать вывод что модель нормальна.

Следующим нашим шагом, после определения нормальности модели, является дисперсионный анализ. Проведя данный анализ, получим значения для оценки наших данных:

Таблица 7 Дисперсионный анализ

	Analysis of Variance; DV: Оценка счастья (happinnes.s				
Effect	Sums of Squares	df	Mean Squares	F	p-value
Regress.	197,0957	5	39,41915	685,6411	0,00
Residual	8,7388	152	0,05749		
Total	205,8346				

Таблица 8 Сводная статистика

Statistic	Summary Statistics; DV: Оценка счастья (happinnes.st Value
Multiple R	0,97854194
Multiple R?	0,95754434
Adjusted R?	0,95614777
F(5,152)	685,641092
p	0
Std.Err. of Estimate	0,23977571

Значение, которое нас интересует в дисперсионном анализе это уровень значимости – $p - value$, которое крайне мало ($< 0{,}5$), это означает что модель можно считать адекватной.

Последняя проверка наших данных заключается в оценке коэффициент детерминации:

Таблица 9 Регрессионная сводка

N=158	Regression Summary for Dependent Variable: Оценка счастья (happinnes.s R= ,97854194 R?= ,95754434 Adjusted R?= ,95614777 F(5,152)=685,64 p<0,0000 Std.Error of estimate: ,23978					
	b*	Std.Err. of b*	b	Std.Err. of b	t(152)	p-value
Intercept			0,507657	0,097459	5,20892	0,000001
Экономика (ВВП на душу населения	0,666569	0,018565	1,893300	0,052730	35,90559	0,000000
Свобода	0,202368	0,021210	1,537652	0,161162	9,54101	0,000000
Доверие (Коррупция в правительстве	0,066991	0,019691	0,639030	0,187832	3,40213	0,000855
щедрость	0,144582	0,018633	1,306769	0,168407	7,75961	0,000000
Остаточная антиутопия	0,507930	0,016930	1,050647	0,035020	30,00150	0,000000

Таблица 10 Значения регрессионной сводки

Statistic	Summary Statistics; DV: Оценка счастья (happinnes.st Value
Multiple R	0,97854194
Multiple R?	0,95754434
Adjusted R?	0,95614777
F(5,152)	685,641092
p	0
Std.Err. of Estimate	0,23977571

В таблице 9 коэффициент детерминации обозначается как $R?$ и равен он $0{,}957$ что означает то, что в данном случае мы можем утверждать о том, что $95{,}7\%$ объясняют отклик, а $4{,}3\%$ – нет, это означает что по данной модели можно построить прогноз, идентичная ситуация и со скорректированным коэффициентом - $Adjusted\ R?$.

Перед тем, как использовать нашу модель для прогнозирования, оценим вклад каждой независимой переменной в предсказание нашего отклика, т.е. независимой переменной:

Таблица 11 Регрессионная сводка

N=158	Regression Summary for Dependent Variable: Оценка счастья (happinnes.s R= ,97854194 R?= ,95754434 Adjusted R?= ,95614777 F(5,152)=685,64 p<0,0000 Std.Error of estimate: ,23978					
	b*	Std.Err. of b*	b	Std.Err. of b	t(152)	p-value
Intercept			0,507657	0,097459	5,20892	0,000001
Экономика (ВВП на душу населения	0,666569	0,018565	1,893300	0,052730	35,90559	0,000000
Свобода	0,202368	0,021210	1,537652	0,161162	9,54101	0,000000
Доверие (Коррупция в правительстве	0,066991	0,019691	0,639030	0,187832	3,40213	0,000855
щедрость	0,144582	0,018633	1,306769	0,168407	7,75961	0,000000
Остаточная антиутопия	0,507930	0,016930	1,050647	0,035020	30,00150	0,000000

По полученным значениям в столбце для значения b мы можем сделать следующий вывод:

С увеличением следующих переменных увеличивается уровень счастья в стране:

1. «Экономика» - самое значительное увеличение.
2. «Свобода» - значительно увеличивается уровень счастья в стране, но меньше, чем от увеличения переменной «Экономика»
3. «Щедрость» - значительно увеличивается уровень счастья в стране, но меньше, чем от увеличения переменной «Свобода»
4. «Остаточная антиутопия» - уровень счастья в стране увеличивается практически пропорционально увеличению переменной
5. «Доверие (Коррупция в правительстве)» - уровень счастья в стране увеличивается, но незначительно

Теперь, после проведения всех вышеописанных действий, мы можем провести прогноз. Для определения насколько верно работает наша модель возьмем значения Швейцарии, а именно:

1. «Экономика» - 1,39651
2. «Свобода» - 0,66557
3. «Доверие» - 0,41978
4. «Щедрость» - 0,29678
5. «Остаточная антиутопия» - 2,51738

Сделаем прогноз по вышеуказанным значениям:

Таблица 12 Прогноз по значениям для Швейцарии

Variable	Predicting Values for (happinnes.sta variable: Оценка счастья		
	b-Weight	Value	b-Weight * Value
Экономика (ВВП на душу населения	1,893300	1,396510	2,644013
Свобода	1,537652	0,665570	1,023415
Доверие (Коррупция в правительстве	0,639030	0,419780	0,268252
щедрость	1,306769	0,296780	0,387823
Остаточная антиутопия	1,050647	2,517380	2,644877
Intercept			0,507657
Predicted			7,476037
-95,0%CL			7,372541
+95,0%CL			7,579533

Полученное по результатам прогноза значение оценки уровня счастья близко к значению Швейцарии: 7,587, что дает нам понять то, что модель, собственно, как и сами прогнозы, работает.

Вывод

По итогам проведения данной лабораторной работы, можно сделать вывод что для данных, которые я использовал, существует явная зависимость между оценкой уровня счастья в стране и следующими факторами:

1. Экономика
2. Свобода
3. Щедрость
4. Остаточная антиутопия
5. Доверие к правительству

Кроме того, полученные данные прошли все требуемые проверки и могут быть использованы для получения прогнозов по уровню счастья в странах.