Дисциплина: Анализ данных
Лабораторное задание №7

Отчет
Тема: Дискриминантный анализ

Выполнил:
студент 3 курса 8 группы
Крутько А.С.

Проверила:
старший преподаватель
Юрова Я.А.

Оглавление

Постановка задачи. 3

Анализируемые данные 4

Практическая часть.....5

Вывод.....16

Постановка задачи.

Целью данной работы было освоить использование проведение дискриминантного анализа. Для чего требовалось выполнить следующее:

1. Используя инструменты статистического пакета Statistica, получить данные для дискриминантного анализа
2. Сделать вывод на основе полученных данных

Анализируемые данные

Для проведения данной работы мною были взяты данные с сайта kaggle.com на тему уровня счастья в мире по странам за 2015 год.

Рисунок 1 QR - код с ссылкой на сайт

Практическая часть.

При проведении дискриминантного анализа, мною была поставлена цель: составить модель из изначальных данных такую, что смогла бы определять группу для введенных данных, используя методы дискриминантного анализа.

Анализ проводился, при помощи данных по странам из рейтинга стран по уровню счастья. Переменные, которые учитывались при проведении анализа приведены ниже:

1. Экономика (ВВП на душу населения) – значение, показывающее в какой степени ВВП, вносит вклад в расчёт показателя счастья
2. Семья – значение, показывающее в какой степени семья вносит вклад в расчёт показателя счастья.
3. Здоровье (продолжительность жизни) – значение, показывающее в какой степени продолжительность жизни, способствовала расчёту показателя счастья.
4. Свобода - значение, показывающее в какой степени свобода способствовала расчёту показателя счастья.
5. Доверие (коррупция в правительстве) - значение, показывающее в какой степени восприятие коррупции способствовало расчёту показателя счастья.
6. Щедрость - значение, показывающее в какой степени щедрость, способствовала расчёту показателя счастья
7. Остаточная антиутопия – значение, выполняющее роль относительного сравнения страны с абстрактной страной с наихудшими уровнем счастья и условиями.

Перед проведением анализа требовалось отобрать переменные, по которым будет определяться дискриминация для данных модели.

	Discriminant Function Analysis Summary (happinnes.sta) No. of vars in model: 7; Grouping: Region (3 grps) Wilks' Lambda: ,17237 approx. F (14,86)=8,6530 p< ,0000					
N=52	Wilks' Lambda	Partial Lambda	F-remove (2,43)	p-value	Toler.	1-Toler. (R-Sqr.)
GDP	0,180406	0,955450	1,00249	0,375377	0,483535	0,516465
Family	0,174901	0,985521	0,31586	0,730836	0,542280	0,457720
Health (life expectancy)	0,287335	0,599888	14,34002	0,000017	0,570876	0,429124
freedom	0,172401	0,999816	0,00395	0,996056	0,429967	0,570033
trust to goverment	0,189344	0,910349	2,11732	0,132730	0,520512	0,479488
generocity	0,201050	0,857344	3,57745	0,036545	0,733784	0,266217
dystopia residual	0,175733	0,980858	0,41958	0,659983	0,927084	0,072916

Таблица 1 Итог дискриминантного анализа функции. Использование всех переменных

Как уже было написано, нужно избавиться от всех малозначимых переменных. Как видно по данной таблице, наименее статистически значима переменная freedom, уберем её из анализа и снова проведем данный анализ переменных. Продолжим выполнять вышеописанные действия, пока все переменные не подойдут для дальнейшего анализа и построения модели.

N=52	Discriminant Function Analysis Summary (happinnes.sta) No. of vars in model: 6; Grouping: Region (3 grps) Wilks' Lambda: ,17240 approx. F (12,88)=10,328 p< ,0000					
	Wilks' Lambda	Partial Lambda	F-remove (2,44)	p-value	Toler.	1-Toler. (R-Sqr.)
GDP	0,180472	0,955277	1,02997	0,365463	0,484433	0,515567
Family	0,175895	0,980133	0,44594	0,643082	0,683882	0,316118
Health (life expectancy)	0,288510	0,597555	14,81668	0,000012	0,572758	0,427242
trust to goverment	0,200744	0,858810	3,61683	0,035135	0,779373	0,220627
generocity	0,203349	0,847808	3,94927	0,026457	0,779429	0,220571
dystopia residual	0,175767	0,980850	0,42952	0,653521	0,927999	0,072001

Таблица 2 Итог дискриминантного анализа функции.

N=52	Discriminant Function Analysis Summary (happinnes.sta) No. of vars in model: 5; Grouping: Region (3 grps) Wilks' Lambda: ,17577 approx. F (10,90)=12,467 p< ,0000					
	Wilks' Lambda	Partial Lambda	F-remove (2,45)	p-value	Toler.	1-Toler. (R-Sqr.)
GDP	0,184140	0,954530	1,07182	0,350962	0,484433	0,515567
Family	0,179118	0,981290	0,42900	0,653798	0,688739	0,311262
Health (life expectancy)	0,293481	0,598904	15,06866	0,000010	0,578740	0,421260
trust to goverment	0,206198	0,852416	3,89556	0,027521	0,790465	0,209535
generocity	0,210125	0,836487	4,39821	0,018002	0,783211	0,216789

Таблица 3 Итог дискриминантного анализа функции.

N=52	Discriminant Function Analysis Summary (happinnes.sta) No. of vars in model: 4; Grouping: Region (3 grps) Wilks' Lambda: ,17912 approx. F (8,92)=15,672 p< ,0000					
	Wilks' Lambda	Partial Lambda	F-remove (2,46)	p-value	Toler.	1-Toler. (R-Sqr.)
GDP	0,186199	0,961972	0,90922	0,409956	0,659289	0,340711
Health (life expectancy)	0,299037	0,598982	15,39849	0,000008	0,623652	0,376348
trust to goverment	0,209131	0,856485	3,85394	0,028350	0,796426	0,203574
generocity	0,218296	0,820528	5,03072	0,010572	0,896976	0,103024

Таблица 4 Итог дискриминантного анализа функции.

N=52	Discriminant Function Analysis Summary (happinnes.sta) No. of vars in model: 3; Grouping: Region (3 grps) Wilks' Lambda: ,18620 approx. F (6,94)=20,640 p< ,0000					
	Wilks' Lambda	Partial Lambda	F-remove (2,47)	p-value	Toler.	1-Toler. (R-Sqr.)
Health (life expectancy)	0,529462	0,351675	43,32302	0,000000	0,907636	0,092364
trust to goverment	0,223792	0,832016	4,74467	0,013277	0,864341	0,135659
generocity	0,222191	0,838011	4,54260	0,015717	0,936847	0,063153

Таблица 5 Итог дискриминантного анализа функции.

Таким образом мы получили подходящие для анализа переменные.

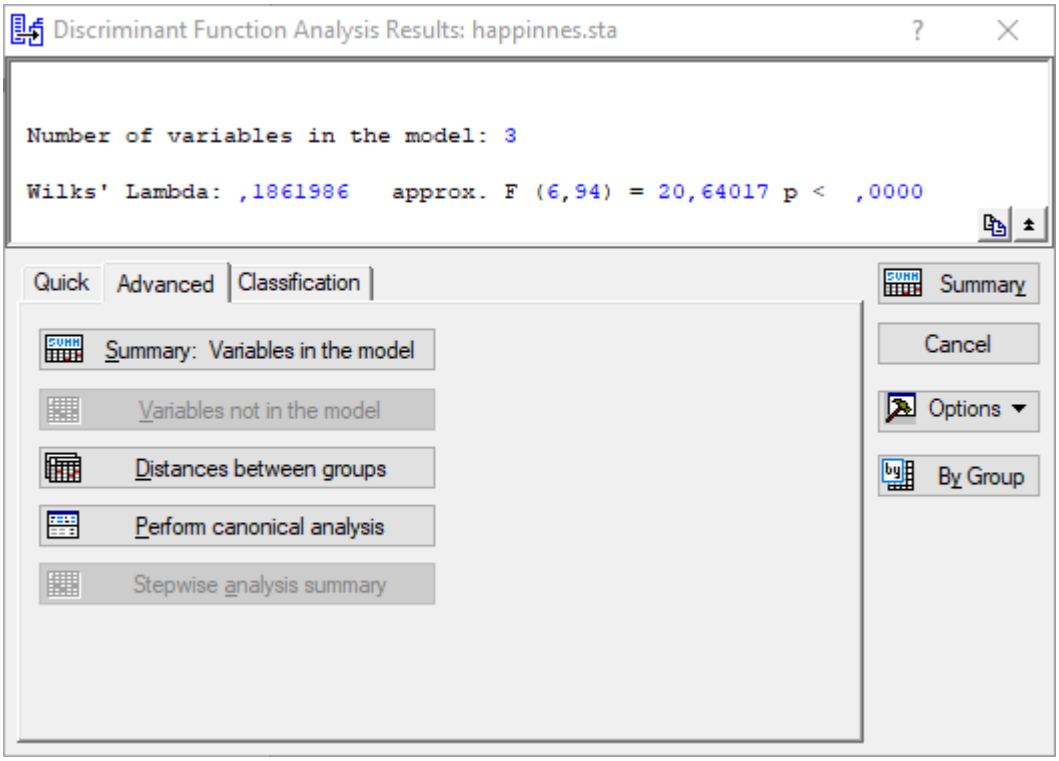

Рисунок 2 Дискриминантный анализ

На данном скриншоте из всех полученных значений можно выделить одно – значение для лямбды – Уилкинсона, оно отвечает за то, насколько хороша дискриминация модели (чем ближе к нулю – тем лучше). Можно заметить, что в моей модели данное значение хоть и близко к нулю, но достаточно велико, что указывает на то, что дискриминация относительно хороша.

Получим дополнительные таблицы значений для анализа нашей модели, по ним можно судить о дискриминации наблюдения, степени неоднородности наших групп данных.

Region	Squared Mahalanobis Distances (happinnes.sta		
	Central and Eastern Europe	North America	Western Europe
Central and Eastern Europe	0,00000	18,01777	15,40935
North America	18,01777	0,00000	1,67608
Western Europe	15,40935	1,67608	0,00000

Рисунок 3 Квадраты расстояний Махалонобиса

Region	F-values; df = 3,47 (happinnes.sta)		
	Central and Eastern Europe	North America	Western Europe
Central and Eastern Europe		10,77824	60,00842
North America	10,77824		0,97858
Western Europe	60,00842	0,97858	

Рисунок 4

Region	p-values (happinnes.sta)		
	Central and Eastern Europe	North America	Western Europe
Central and Eastern Europe		0,000017	0,000000
North America	0,000017		0,410888
Western Europe	0,000000	0,410888	

Рисунок 5

Roots Removed	Chi-Square Tests with Successive Roots Removed (happinnes.s					
	Eigen-value	CanonicI R	Wilks' Lambda	Chi-Sqr.	df	p-value
0	4,059222	0,895735	0,186199	80,68519	6	0,000000
1	0,061549	0,240790	0,942020	2,86698	2	0,238475

Рисунок 6 Хи-Квадрат тесты

Если в последней таблице взглянуть на значение параметра p, то можно сделать вывод что вторая функция не значима из этого следует, что её не нужно брать в расчет.

Variable	Raw Coefficients (happinnes.sta for Canonical Variables	
	Root 1	Root 2
Health (life expectancy	14,6593	-5,95146
trust to goverment	3,9226	-2,45513
generocity	3,7703	9,13887
Constant	-13,1923	3,10227
Eigenval	4,0592	0,06155
Cum.Prop	0,9851	1,00000

Таблица 6 Чистые коэффициенты

Variable	Standardized Coefficients (happinnes.st for Canonical Variables	
	Root 1	Root 2
Health (life expectancy	0,937972	-0,380804
trust to goverment	0,485345	-0,303771
generocity	0,388944	0,942762
Eigenval	4,059222	0,061549
Cum.Prop	0,985064	1,000000

Таблица 7 Стандартизированные коэффициенты

По данной таблице можно сделать вывод что в первую функцию максимальный вклад даёт переменная Health, а во вторую – переменная generosity. И по 5 строке можно сделать вывод о том, что первая функция ответственна за 98% объясненной дисперсии.

Variable	Factor Structure Matrix (happinnes.sta Correlations Variables - Canonical Root (Pooled-within-groups correlations)	
	Root 1	Root 2
Health (life expectancy	0,746126	-0,401022
trust to goverment	0,299565	0,043545
generocity	0,397902	0,912761

Таблица 8 Фактор - структурная матрица

В данной таблице приведены объединенные внутригрупповые корреляции переменных в соответствии с каждой функцией

Обычно данные структурные коэффициенты используют для содержательной интерпретации функций. Опять же, по данной таблице можно заметить факт, который был описан до этого: переменная health наиболее коррелирует с первой функцией, а переменная generosity – со второй функцией, остальные переменные слабо коррелируют с каждой из функций.

	Means of Canonical Variables (happinnes.st	
Group	Root 1	Root 2
Central and Eastern Europe	-1,74154	0,003243
North America	2,33993	1,169155
Western Europe	2,18213	-0,115826

Таблица 9 Средние канонических переменных

По данной таблице мы можем определить группы, которые лучше всего идентифицируют конкретные функции. В нашей таблице мы видим, что первая функция лучше характеризует группы “North America” “Western Europe”, в то время как вторая функция лучше характеризует только лишь группу “North America”.

Построим таблицу нестандартизированых канонических значений:

	Unstandardized Canonical Scores (happinnes.s		
Case	Group	Root 1	Root 2
1	Western Europe	3,3740	-0,81899
2	Western Europe	2,9022	1,10125
3	Western Europe	2,8133	-0,17042
4	Western Europe	2,5244	0,10888
5	North America	3,1036	1,08992
6	Western Europe	2,3447	-1,07095
7	Western Europe	2,9391	1,35851
8	Western Europe	3,2474	-0,08122
13	Western Europe	1,8407	0,36832
15	North America	1,5763	1,24839
17	Western Europe	2,8183	-0,73276
18	Western Europe	2,7891	1,26389
19	Western Europe	1,6753	-0,75421
21	Western Europe	3,3544	1,64672
26	Western Europe	1,8023	-0,16343
29	Western Europe	1,9471	-1,90644
31	Central and Eastern Europe	-0,3008	-1,01423
36	Western Europe	1,7546	-1,07640
37	Western Europe	2,2977	2,21807
44	Central and Eastern Europe	-2,3600	0,87519
45	Central and Eastern Europe	-0,8543	-0,13395

Таблица 10 Нестандартизрованные канонические значения

По данной таблице можно исследовать корреляцию одной из переменных со значением для определенного случая в таблице

Построим диаграмму рассеивания для графического представления нашей модели:

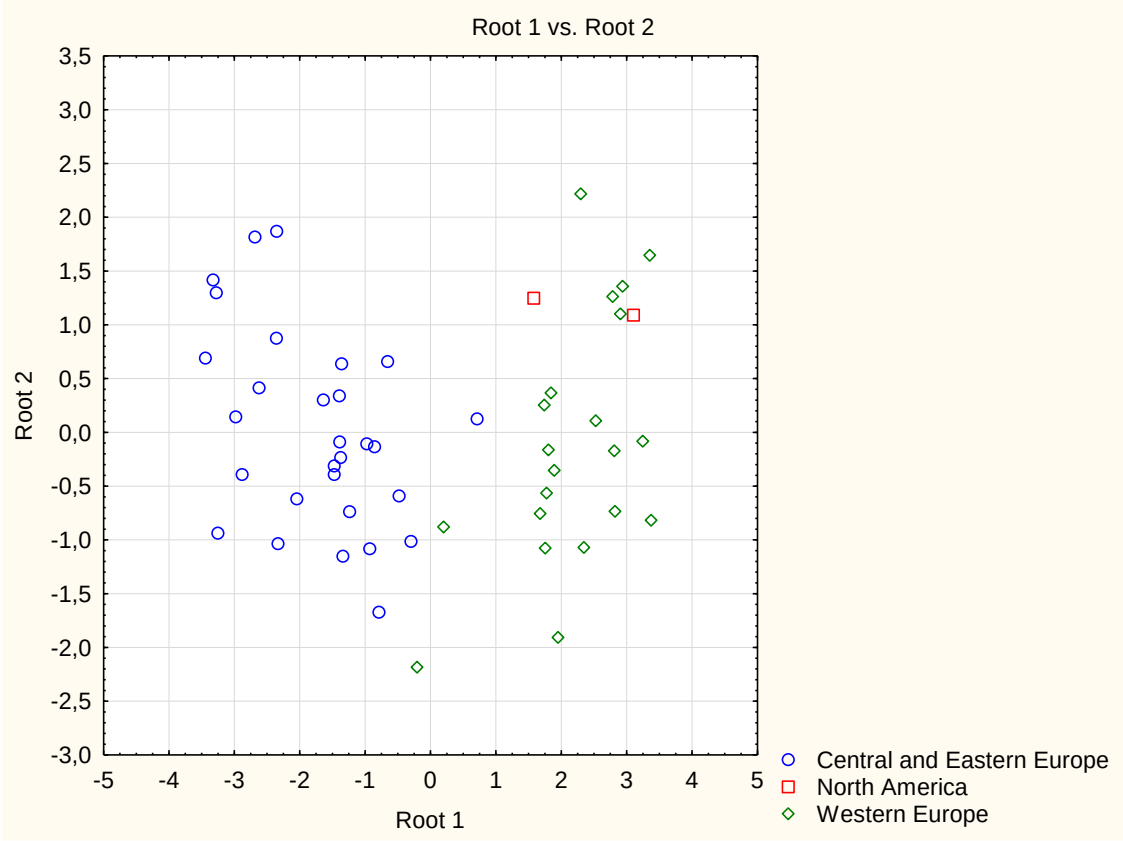

Рисунок 7 Диаграмма рассеивания

Не считая группы “North America” можно заметить, что группы на данном графике явно разделены на области. Т.к. рассматривается набор данных, характеризующий уровень счастья в мире, то на такое поведение у группы “North America” скорее всего влияет общий уровень жизни в этой части мира, сопоставимый с другой группой стран – “Western Europe”. Ну и, кроме этого, на подобный результат мог повлиять факт того, что в данном регионе слишком мало стран, чтобы хоть как-то его отличать от другого региона.

Построим функции классификаций:

	Classification Functions; grouping:Region (happinnes.sta		
Variable	Central and Eastern Europe p=,55769	North America p=,03846	Western Europe p=,40385
Health (life expectancy)	198,1080	251,001	256,335
trust to goverment	32,4900	45,638	48,173
generocity	19,2145	45,258	32,920
Constant	-74,6522	-129,458	-127,978

Рисунок 8 Классификационные функции

По полученным функциям классификации можно выписать модель, которую уже далее можно будет использовать для анализа.

$$F_1 = 198{,}1080x_1 + 32{,}4900x_2 + 19{,}2145x_3 - 74{,}6522$$
$$F_2 = 251{,}001x_1 + 45{,}6380x_2 + 45{,}258x_3 - 129{,}458$$
$$F_3 = 256{,}335x_1 + 48{,}173x_2 + 32{,}920x_3 - 127{,}978$$

Построим классификационную матрицу:

Group	Classification Matrix (happinnes.sta) Rows: Observed classifications Columns: Predicted classifications			
	Percent Correct	Central and Eastern Europe p=,55769	North America p=,03846	Western Europe p=,40385
Central and Eastern Europe	96,55173	28	0	1
North America	0,00000	0	0	2
Western Europe	90,47619	2	0	19
Total	90,38461	30	0	22

Таблица 11

Как можно заметить, в точности, как и на диаграмме рассеивания страны из группы “North America” были отнесены к группе “Western Europe”.

По таблицам ниже можно увидеть какие именно данные были неправильно классифицированы, в частности по таблице «квадратов расстояния Махалонобиса» можно увидеть к каким группам он ближе всего определил наши данные

Case	Squared Mahalanobis Distances from Group Centroids (happinnes.sta) Incorrect classifications are marked with *			
	Observed Classif.	Central and Eastern Europe p=,55769	North America p=,03846	Western Europe p=,40385
1	Western Europe	28,4182	6,5956	3,4886
2	Western Europe	23,8623	1,4133	3,0923
3	Western Europe	24,5480	5,7899	4,1727
4	Western Europe	19,2390	2,1881	1,1975
* 5	North America	24,8934	0,8268	2,5403
6	Western Europe	20,2168	7,3838	3,3044
7	Western Europe	23,9296	0,5795	2,9313
8	Western Europe	26,9097	4,3999	3,1489
13	Western Europe	13,0522	0,9769	0,4373
* 15	North America	12,7958	0,8268	2,4655
17	Western Europe	22,4805	4,9925	1,9317
18	Western Europe	22,1632	0,2580	2,3193
19	Western Europe	12,2672	4,1599	0,6832
21	Western Europe	28,7641	1,3517	4,5753
26	Western Europe	12,5866	2,0650	0,1467
29	Western Europe	17,2562	9,6168	3,2647
31	Central and Eastern Europe	3,9509	12,5805	7,8119
36	Western Europe	14,9309	6,9277	2,6480
37	Western Europe	22,1303	2,0115	6,3699
44	Central and Eastern Europe	5,2783	26,3109	25,7481
45	Central and Eastern Europe	1,3195	12,4151	9,7341
50	Western Europe	15,1366	5,7817	2,8259
52	Central and Eastern Europe	4,0603	31,5836	31,8179
54	Central and Eastern Europe	1,6838	29,4722	26,8369
* 55	Central and Eastern Europe	7,4648	5,1503	3,6328
56	Central and Eastern Europe	1,5964	26,8546	21,3944
59	Central and Eastern Europe	1,3800	17,0038	12,6506
60	Central and Eastern Europe	0,9758	12,9926	10,3455
62	Central and Eastern Europe	1,8546	19,2794	13,8343
64	Central and Eastern Europe	3,1782	35,7501	30,2489
66	Western Europe	13,7613	2,9402	0,5626
67	Western Europe	13,9463	2,9363	2,0741
69	Central and Eastern Europe	4,1884	25,6751	27,4274
70	Central and Eastern Europe	9,0495	39,3552	37,9739
73	Central and Eastern Europe	1,9570	15,8702	10,7308
77	Central and Eastern Europe	3,9274	22,5828	24,5767
80	Central and Eastern Europe	2,4566	30,6833	26,7025
83	Central and Eastern Europe	0,2690	15,6500	12,9129
86	Central and Eastern Europe	0,8031	16,3968	13,2954
87	Central and Eastern Europe	0,6419	15,0350	13,4060
* 88	Western Europe	6,0062	10,2583	5,9941
89	Central and Eastern Europe	0,1593	16,6367	14,8272
[illegible]	[illegible]	[illegible]	[illegible]	[illegible]

Таблица 12

Case	Classification of Cases (happinnes.sta) Incorrect classifications are marked with * Observed Classif.	1 p=,55769	2 p=,03846	p
1	Western Europe	Western Europe	North America	Central ar
2	Western Europe	Western Europe	North America	Central ar
3	Western Europe	Western Europe	North America	Central ar
4	Western Europe	Western Europe	North America	Central ar
* 5	North America	Western Europe	North America	Central ar
6	Western Europe	Western Europe	North America	Central ar
7	Western Europe	Western Europe	North America	Central ar
8	Western Europe	Western Europe	North America	Central ar
13	Western Europe	Western Europe	North America	Central ar
* 15	North America	Western Europe	North America	Central ar
17	Western Europe	Western Europe	North America	Central ar
18	Western Europe	Western Europe	North America	Central ar
19	Western Europe	Western Europe	North America	Central ar
21	Western Europe	Western Europe	North America	Central ar
26	Western Europe	Western Europe	North America	Central ar
29	Western Europe	Western Europe	North America	Central ar
31	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
36	Western Europe	Western Europe	North America	Central ar
37	Western Europe	Western Europe	North America	Central ar
44	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
45	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
50	Western Europe	Western Europe	North America	Central ar
52	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
54	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
* 55	Central and Eastern Europe	Western Europe	Central and Eastern Europe	
56	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
59	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
60	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
62	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
64	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
66	Western Europe	Western Europe	North America	Central ar
67	Western Europe	Western Europe	North America	Central ar
69	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
70	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
73	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
77	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
80	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
83	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
86	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
87	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
* 88	Western Europe	Central and Eastern Europe	Western Europe	
89	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
93	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
95	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
96	Central and Eastern Europe	Central and Eastern Europe	Western Europe	
* 102	Western Europe	Central and Eastern Europe	Western Europe	

Таблица 13

Взглянем на таблицу ниже, тут представлены вероятности соответствия определенной записи каждой группе. Данные вероятности определяются посредством расстояний Махалонобиса и постариорных вероятностей.

Case	Posterior Probabilities (happinnes.sta) Incorrect classifications are marked with *			
	Observed Classif.	Central and Eastern Europe p=,55769	North America p=,03846	Western Europe p=,40385
1	Western Europe	0,000005	0,019745	0,980249
2	Western Europe	0,000035	0,180656	0,819309
3	Western Europe	0,000050	0,040698	0,959252
4	Western Europe	0,000158	0,054845	0,944997
* 5	North America	0,000016	0,183223	0,816761
6	Western Europe	0,000290	0,012232	0,987478
7	Western Europe	0,000029	0,235861	0,764110
8	Western Europe	0,000009	0,048483	0,951508
13	Western Europe	0,002341	0,067630	0,930029
* 15	North America	0,006445	0,176552	0,817003
17	Western Europe	0,000047	0,020197	0,979756
18	Western Europe	0,000053	0,210687	0,789260
19	Western Europe	0,004128	0,016400	0,979472
21	Western Europe	0,000005	0,323093	0,676902
26	Western Europe	0,002643	0,035119	0,962238
29	Western Europe	0,001258	0,003956	0,994786
31	Central and Eastern Europe	0,904180	0,000834	0,094986
36	Western Europe	0,002930	0,011050	0,986020
37	Western Europe	0,000283	0,456936	0,542781
44	Central and Eastern Europe	0,999972	0,000002	0,000026
45	Central and Eastern Europe	0,989072	0,000266	0,010662
50	Western Europe	0,002860	0,021203	0,975937
52	Central and Eastern Europe	0,999999	0,000000	0,000001
54	Central and Eastern Europe	0,999997	0,000000	0,000002
* 55	Central and Eastern Europe	0,162892	0,035738	0,801370
56	Central and Eastern Europe	0,999963	0,000000	0,000036
59	Central and Eastern Europe	0,997394	0,000028	0,002578
60	Central and Eastern Europe	0,993190	0,000168	0,006641
62	Central and Eastern Europe	0,998179	0,000011	0,001810
64	Central and Eastern Europe	0,999999	0,000000	0,000001
66	Western Europe	0,001824	0,028140	0,970037
67	Western Europe	0,003424	0,058078	0,938498
69	Central and Eastern Europe	0,999992	0,000001	0,000007
70	Central and Eastern Europe	1,000000	0,000000	0,000000
73	Central and Eastern Europe	0,991008	0,000065	0,008927
77	Central and Eastern Europe	0,999970	0,000006	0,000024
80	Central and Eastern Europe	0,999996	0,000000	0,000004

Таблица 14

После получения вышеописанных данных мы можем проверить работу модели путем добавления новых записей в набор данных.

Я добавил новую запись в таблицу с данными, а именно:

		Happiness score	GDP	Family	Health	Freedom	Trust to government	Generosity	Dystopia residual
		6	1,2	1,2	0,8	0,6	0,35	0,3	2,5

После вывода постериорных вероятностей мы получаем следующие данные:

---	0,051732	0,047895	0,900373

Что означает, что он счел его за запись, принадлежащую группе “Western Europe”.

Добавим ещё 3 новых записи. Первые две записи должны быть отнесены в группу “Eastern and central Europe”, в то время как последняя – “Western Europe“

		Happiness score	GDP	Family	Health	Freedom	Trust to governm ent	Generosity	Dystopia residual
		5,8	1,11	1,12	0,64	0,5	0,1	0,15	2,2
		5,85	1,13	1,06	0,7	0,4	0,07	0,16	1,85
		7,5	1,29	1,3	0,95	0,7	0,5	0,3	2,5

Снова выведем постериорные вероятности:

Case	**Observed Classif.**	Central and Eastern Europe p=,55769	North America p=,03846	Western Europe p=,40385
160	---	0,999996	0,000000	0,000004
161	---	0,999903	0,000003	0,000094
162	---	0,000001	0,016075	0,983924

Рисунок 9

Как можно заметить, он практически со 100% точностью определил записи к нужным группам.

Вывод

По результатам проведенного дискриминантного анализ можно сделать следующий вывод: выбранные мною данные были не идеальны для анализа групп “North America” и “Eastern Europe”, ибо, как это можно было заметить на диаграмме рассеивания и многих других полученных таблицах значений, данные этих двух групп плохо дискриминируются, что повлияло на конечный результат анализа: данные, которые должны были быть определены к группе “North America” определялись к группе “Eastern Europe”.